

# 1 PRINCÍPIOS ELEMENTARES PARA A ANÁLISE DE DADOS UTILIZANDO OS MODELOS DE REGRESSÃO LINEARES

Antes de adentrar o universo dos modelos lineares, este capítulo tem como objetivo revisar importantes tópicos estatísticos: propriedades do estimador média amostral, o estimador de mínimos quadrados, o estimador de máxima verossimilhança, dentre outros. O objetivo é apresentar conceitos e propriedades em um contexto mais simples para, nos capítulos seguintes, estender esses conceitos aos modelos lineares e aos modelos lineares generalizados. Neste capítulo, assume-se que existe apenas uma variável aleatória de interesse  $Y$  para a qual uma amostra de tamanho  $n$  está disponível. Distingue-se uma variável aleatória de uma instância, ou um valor observado, pela nomenclatura: valores maiúsculos são utilizados para variáveis aleatória de valores minúsculos para suas instâncias.

Seja  $Y_i$  variáveis aleatória independentes com distribuição normal, com média  $\mu$  e variância  $\sigma^2$ ,  $Y_i \sim \text{Normal}(\mu, \sigma^2)$ . Vamos definir  $y_i$  como uma instância de  $Y_i$ . Seja também uma amostra de tamanho  $n$ :  $\{y_1, y_2, \dots, y_n\}$ .

## 1.1 O ESTIMADOR MÉDIA AMOSTRAL

Define-se a média amostral como:  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ . Pode-se então caracterizar a variável aleatória  $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$ . A distribuição de  $\bar{Y}$  é normal com média  $\mu$  e variância  $\frac{\sigma^2}{n}$ ,  $\bar{Y} \sim \text{Normal}\left(\mu, \frac{\sigma^2}{n}\right)$ . Este fato pode ser verificado utilizando princípios básicos de probabilidade. Utilizando o operador esperança matemática,  $E(\cdot)$ , têm-se que:

$$\begin{aligned} E(\bar{Y}) &= E\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{1}{n} E\left(\sum_{i=1}^n Y_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n E(Y_i) = \frac{1}{n} \sum_{i=1}^n \mu \\ &= \frac{1}{n} n\mu \\ &= \mu \end{aligned} \tag{1.1}$$

Aplicando o operador variância,  $\text{Var}(\cdot)$ , novamente assumindo que as variáveis aleatórias  $Y_i$  são independentes e identicamente distribuídas, então:

$$\begin{aligned}
\text{Var}(\bar{Y}) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n Y_i\right) \\
&= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 \\
&= \frac{1}{n^2} n \sigma^2 \\
&= \frac{\sigma^2}{n}
\end{aligned} \tag{1.2}$$

Ambas as equações 1.1 e 1.2 podem ser interpretadas da seguinte forma: caso seja coletada uma amostra de tamanho  $n$  de uma variável aleatória normal com média  $\mu$  e variância  $\sigma^2$ , mesmo desconhecendo os parâmetros  $\mu$  e  $\sigma^2$ , é possível afirmar que a média amostral oscila em torno do parâmetro da média. Além disso, à medida que o tamanho da amostra aumenta, menor seja a dispersão da média amostral com relação ao parâmetro  $\mu$ .

## 1.2 O ESTIMADOR DE MÍNIMOS QUADRADOS

Vamos considerar a estrutura do modelo de regressão mais simples possível:  $Y_i = \beta_0 + \epsilon$ , onde  $\epsilon$  é uma variável aleatória normal com média 0 (zero) e variância  $\sigma^2$ ,  $\epsilon \sim \text{Normal}(0, \sigma^2)$ , e  $\beta_0$  é uma constante. Este modelo é uma representação alternativa para o caso onde  $Y_i \sim \text{Normal}(\mu, \sigma^2)$ . É possível mostrar que a variável aleatória  $Y_i$  pode ser escrita a partir de um modelo aditivo:  $Y_i = \mu + \epsilon$ , onde  $\mu$  é uma constante que define a média de  $Y_i$  e  $\epsilon$  é uma variável aleatória com média zero e variância  $\sigma^2$  que define a variância de  $Y_i$ . No caso inicialmente apresentado, o parâmetro de média  $\mu$  e o parâmetro  $\beta_0$  são equivalentes.

Neste caso, queremos encontrar a solução para o seguinte problema de otimização:

$$\hat{\beta}_0 = \arg \min_{\beta_0} \sum_{i=1}^n (y_i - \beta_0)^2 \tag{1.3}$$

A solução para a equação (1.3) é:

$$\frac{\partial \sum_{i=1}^n (y_i - \hat{\beta}_0)^2}{\partial \beta_0} = 0$$

$$\sum_{i=1}^n 2 (y_i - \hat{\beta}_0) \cdot (-1) = 0$$

$$-2 \sum_{i=1}^n y_i + 2 \sum_{i=1}^n \hat{\beta}_0 = 0$$

$$2n\hat{\beta}_0 = 2 \sum_{i=1}^n y_i$$

$$\hat{\beta}_0 = \frac{1}{n} \sum_{i=1}^n y_i \tag{1.4}$$

Note que a solução de mínimos quadrados para o parâmetro  $\beta_0$  também é a média amostral,  $\hat{\beta}_0 = \bar{y}$ . Neste caso, uma vez que  $\epsilon$  é uma variável aleatória, então  $Y_i$  também é uma variável aleatória normal com média e variância definidas por:

$$\begin{aligned} E(Y_i) &= E(\beta_0 + \epsilon) \\ &= \beta_0 + E(\epsilon) \\ &= \beta_0 \end{aligned} \quad (1.5)$$

$$\begin{aligned} Var(Y_i) &= Var(\beta_0 + \epsilon) \\ &= Var(\beta_0) + Var(\epsilon) \\ &= 0 + Var(\epsilon) \\ &= \sigma^2 \end{aligned} \quad (1.6)$$

então:  $Y_i \sim Normal(\mu = \beta_0, \sigma^2)$ . Neste caso, como o parâmetro de média é desconhecido, utiliza-se o estimador de mínimos quadrados ou a média amostral.

### 1.3 O ESTIMADOR DE MÁXIMA VEROSSIMILHANÇA

O estimador de máxima verossimilhança de um parâmetro populacional requer a especificação da distribuição de probabilidade da variável de interesse. Seja então uma amostra de tamanho  $n$  de variáveis aleatórias independentes e identicamente distribuídas,  $\{Y_1, Y_2, \dots, Y_n\}$ ,  $Y_i \sim Normal(\beta_0, \sigma^2)$ . A função de verossimilhança é definida pela probabilidade de observar a amostra  $\{Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n\}$  dado o modelo de distribuição de probabilidade especificado:

$$\begin{aligned} F(\beta_0, \sigma) &= P(Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n), \text{ assumindo independência:} \\ &= P(Y_1 = y_1) \times P(Y_2 = y_2) \times \dots \times P(Y_n = y_n) \\ &= \prod_{i=1}^n P(Y_i = y_i), \text{ sendo identicamente distribuídos:} \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \left( \frac{y_i - \beta_0}{\sigma} \right)^2} \\ &= \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\frac{1}{2} \frac{\sum_{i=1}^n (y_i - \beta_0)^2}{\sigma^2}} \end{aligned} \quad (1.7)$$

O estimador de máxima verossimilhança é a solução que maximiza a função de verossimilhança, ou seja, os valores de  $\beta_0$  e  $\sigma^2$  que maximizam a probabilidade de ser observada a amostra  $\{Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n\}$ . A maximização pode ser realizada, sem alteração da solução, do logaritmo da função de verossimilhança:

$$\log F(\beta_0, \sigma) = -n \log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0)^2$$

A solução de máxima verossimilhança para o parâmetro  $\beta_0$  é:

$$\begin{aligned}
\frac{\partial \log F(\beta_0, \sigma)}{\partial \beta_0} &= 0 \\
\frac{\partial}{\partial \beta_0} \left[ -n \log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0)^2 \right] &= 0 \\
\frac{\partial}{\partial \beta_0} \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0)^2 \right] &= 0 \\
\frac{\partial}{\partial \beta_0} \left[ -\sum_{i=1}^n (y_i - \beta_0) \right] &= 0 \\
-2 \sum_{i=1}^n (y_i - \beta_0) (-1) &= 0 \\
+2 \sum_{i=1}^n y_i - 2 \sum_{i=1}^n \beta_0 &= 0 \\
-2n\beta_0 &= -2 \sum_{i=1}^n y_i \\
\hat{\beta}_0 &= \frac{1}{n} \sum_{i=1}^n y_i \quad (1.8)
\end{aligned}$$

Ou seja, a solução de mínimos quadrados e o estimador de máxima verossimilhança são equivalentes e iguais à média amostral, supondo o modelo de distribuição normal para a variável aleatória de interesse. Modelos mais complexos serão objetos futuros de averiguação e exercícios.

#### 1.4 INFERÊNCIA ESTATÍSTICA COM RELAÇÃO AO PARÂMETRO $\mu$

Inicialmente, vamos considerar a distribuição da média amostral para o caso de variáveis aleatórias com distribuição normal,  $Y_i \sim \text{Normal}(\mu, \sigma^2)$  e  $\bar{Y} \sim \text{Normal}\left(\mu, \frac{\sigma^2}{n}\right)$ . Se os parâmetros  $\mu$  e  $\sigma^2$  fossem conhecidos, então poderíamos inferir sobre possíveis valores da média amostral a partir da construção de faixas de referência:

$$FR(\bar{Y}, \alpha) : \mu \pm Z_{\alpha/2} \times \frac{\sigma}{\sqrt{n}} \quad (1.9)$$

Por exemplo, assumindo um nível de confiança:  $1 - \alpha = 0.997$  (99.7%) então  $Z_{\alpha/2} = 3$ . Uma vez que o parâmetro populacional  $\mu$  é desconhecido, podemos construir um intervalo centrado no valor observado da média amostral,  $\bar{Y}$ , e então inferir sobre os valores mais prováveis para o parâmetro populacional  $\mu$ . Neste caso, o intervalo é conhecido como intervalo de confiança (IC) para a média populacional:

$$IC(\mu, \alpha) : \bar{Y} \pm Z_{\alpha/2} \times \frac{\sigma}{\sqrt{n}} \quad (1.10)$$

É importante destacar que, em ambos os casos mostrados nas equações 1.9 e 1.10, assume-se que o parâmetro de variância  $\sigma^2$  é conhecido. Tal suposição é irreal na grande maioria dos casos. A figura 1.1 apresenta uma ilustração das diferenças entre faixa de referência e intervalo de confiança.

Nos casos onde a variância populacional é desconhecida, faz-se a substituição pela estimativa do desvio padrão amostral,  $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$ . Neste caso, a incerteza associada ao estimador do desvio padrão é considerada nos intervalos da confiança e na faixa de referência, a partir da substituição do escore  $Z_{\alpha/2}$  pelo escore  $t_{(\frac{\alpha}{2}, n-1)}$ :



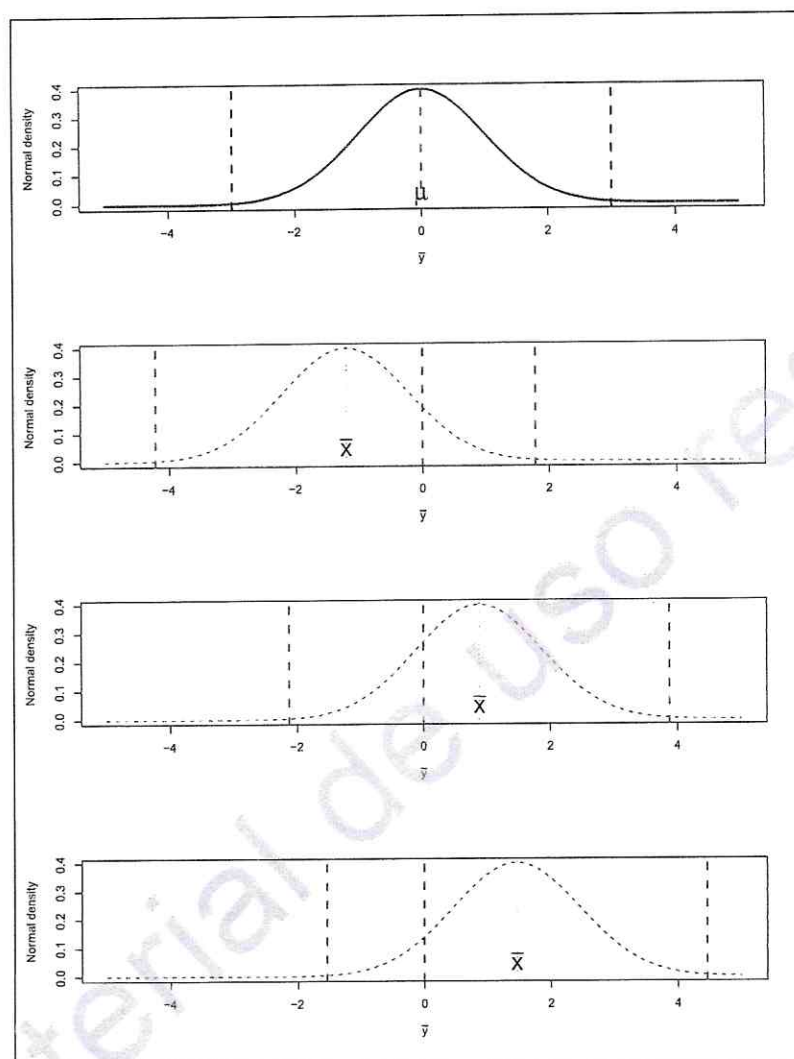


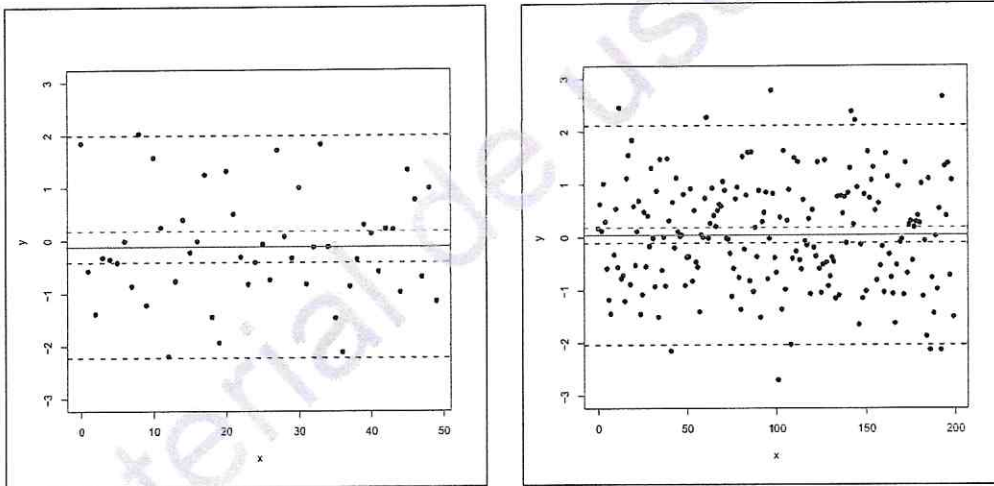
Figura 1.1: Diferenças entre faixa de referência para a média amostral e intervalo de confiança para o parâmetro média populacional. A faixa de referência está centrada no valor de  $\mu$  e indica a faixa de valores mais prováveis para a média amostral. O intervalo de confiança está centrado na média amostral e indica o intervalo mais provável de conter o verdadeiro valor da média populacional,  $\mu$ .

$$FR(\bar{Y}, \alpha) : \mu \pm t_{\left(\frac{\alpha}{2}, n-1\right)} \times \frac{S}{\sqrt{n}} \quad (1.11)$$

$$IC(\mu, \alpha) : \bar{Y} \pm t_{\left(\frac{\alpha}{2}, n-1\right)} \times \frac{S}{\sqrt{n}} \quad (1.12)$$

### 1.5 INTERVALO DE CONFIANÇA VERSUS INTERVALO DE PREDIÇÃO

Supondo que  $Y \sim N(\mu, \sigma^2)$  e que  $\bar{Y} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ , o intervalo de confiança para o parâmetro  $\mu$  procura caracterizar o intervalo mais provável para a ocorrência do parâmetro da média,  $\mu$  :  $\bar{Y} \pm t_{\left(\frac{\alpha}{2}, n-1\right)} \times \frac{S}{\sqrt{n}}$ . Ou seja, a largura do intervalo de confiança é afetado pelo tamanho da amostra  $n$ . Já o intervalo de predição procura caracterizar o intervalo mais provável para a ocorrência de valores futuros, ou seja, novos valores para  $Y_i, i > n$ . Uma vez definidos os estimadores da média,  $\hat{\mu}$ , e desvio padrão amostral,  $S$ , o intervalo pode ser construído assumindo  $Y_i \sim N(\hat{\mu}, S^2)$ . Em geral, o intervalo de predição requer ajustes adicionais em função das incertezas associadas aos estimadores da média e desvio padrão. Mas, o intervalo de predição não é tão afetado pelo tamanho da amostra  $n$  do que o intervalo de confiança. A figura 1.2 ilustra as diferenças entre o intervalo de confiança e o intervalo de predição. Sucintamente, o intervalo de confiança diminui com o aumento do tamanho da amostra. O intervalo de predição se torna estável com o aumento do tamanho da amostra, mas não diminui.



(a) Intervalo de predição e intervalo de confiança para amostra de tamanho  $n = 50$ .  
(b) Intervalo de predição e intervalo de confiança para amostra de tamanho  $n = 200$ .

Figura 1.2: Estimativas de intervalo de confiança para a média populacional (linhas horizontais em vermelho) e intervalo de predição (linhas horizontais em preto) para novas observações considerando tamanhos de amostra  $n = 50$  e  $n = 100$ .

### 1.6 TESTE DE HIPÓTESES PARA A MÉDIA POPULACIONAL

Uma vez que seja especificada uma condição de igualdade para o parâmetro de média,  $\mu = \mu_0$  é possível adaptar a faixa de referência para avaliar a hipótese nula  $H_0 : \mu = \mu_0$ . Ou seja, neste contexto, uma hipótese nula consiste em definir uma condição de igualdade para um

parâmetro de interesse. Caso a hipótese nula seja verdadeira a média amostral estará contida no intervalo  $\mu_0 \pm t_{(\frac{\alpha}{2}, n-1)} \times \frac{s}{\sqrt{n}}$  com probabilidade  $1 - \alpha$ . Caso a média amostral não esteja no intervalo, têm-se evidência a favor da hipótese alternativa, que é o complemento da hipótese nula,  $H_1 : \mu \neq \mu_0$

### 1.7 VÍCIO E VARIÂNCIA DO ESTIMADOR DESVIO PADRÃO AMOSTRAL

Até o momento, foram avaliadas as propriedades do estimados média amostral ( $\bar{Y}$ ). Neste ponto, queremos avaliar propriedades do estimador variância amostral. Considere  $Y$  uma variável aleatória com distribuição normal,  $Y \sim Normal(\mu, \sigma^2)$ , queremos avaliar a esperança do seguinte estimador de  $\sigma^2$ :

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

$$\begin{aligned} E \left[ \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \right] &= \frac{1}{n} E \left[ \sum_{i=1}^n (Y_i - \bar{Y})^2 \right] \\ &= \frac{1}{n} E \left[ \sum_{i=1}^n (Y_i - \mu + \mu - \bar{Y})^2 \right] \\ &= \frac{1}{n} E \left\{ \sum_{i=1}^n [(Y_i - \mu) - (\bar{Y} - \mu)]^2 \right\} \\ &= \frac{1}{n} E \left[ \sum_{i=1}^n (Y_i - \mu)^2 - 2 \sum_{i=1}^n (Y_i - \mu) (\bar{Y} - \mu) + \sum_{i=1}^n (\bar{Y} - \mu)^2 \right] \\ &= \frac{1}{n} E \left[ \sum_{i=1}^n (Y_i - \mu)^2 \right] - 2 \frac{1}{n} E \left[ \underbrace{\sum_{i=1}^n (Y_i - \mu) (\bar{Y} - \mu)}_a \right] + \frac{1}{n} E [n (\bar{Y} - \mu)^2] \end{aligned}$$

$$\begin{aligned} a : \sum_{i=1}^n (Y_i - \mu) (\bar{Y} - \mu) &= \sum_{i=1}^n (Y_i \bar{Y} - \mu Y_i - \mu \bar{Y} + \mu^2) \\ &= \bar{Y} \sum_{i=1}^n (Y_i) - \mu \sum_{i=1}^n (Y_i) - n \mu \bar{Y} + n \mu^2 \\ &= n \bar{Y}^2 - n \mu \bar{Y} - n \mu \bar{Y} + n \mu^2 \\ &= n (\bar{Y} - \mu)^2 \end{aligned}$$

logo, considerando a seguinte propriedade:  $Var(Y) = E[(Y - E[Y])^2]$ , podemos concluir que:

$$\begin{aligned} E \left[ \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \right] &= \frac{1}{n} E \left[ \sum_{i=1}^n (Y_i - \mu)^2 \right] - 2 \frac{1}{n} E [n (\bar{Y} - \mu)^2] + \frac{1}{n} E [n (\bar{Y} - \mu)^2] \\ &= \frac{1}{n} \sum_{i=1}^n E (Y_i - \mu)^2 - \frac{1}{n} E [n (\bar{Y} - \mu)^2] \\ &= \frac{1}{n} n \sigma^2 - \underbrace{E [(\bar{Y} - \mu)^2]}_{Var(\bar{Y})} \\ &= \frac{1}{n} n \sigma^2 - \frac{1}{n} \sigma^2 \\ &= \frac{n-1}{n} \sigma^2 \end{aligned}$$

Ou seja,  $\frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2$  é um estimador viciado para  $\sigma^2$ . Se  $E \left[ \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \right] = \frac{n-1}{n} \sigma^2$ , podemos encontrar um estimador não viesado multiplicando o estimador viciado por  $\frac{n}{n-1}$ :

$$\frac{n}{n-1} E \left[ \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \right] = \frac{n}{n-1} \times \frac{n-1}{n} \sigma^2 = \sigma^2$$

ou seja:

$$E \left[ \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 \right] = \sigma^2 \quad (1.13)$$

Diferente do estimador média amostral, o estimador não viciado para a variância utiliza  $\frac{1}{n-1}$  no denominador ao contrário do tradicional  $\frac{1}{n}$ . A justificativa para isso, como demonstrado, é o fato de que  $\frac{1}{n}$  gera um estimador viciado, ao fato que  $\frac{1}{n-1}$  gera um estimador não viciado.

### 1.8 O TEOREMA CENTRAL DO LIMITE / TEOREMA DO LIMITE CENTRAL

Seja  $Y_1, Y_2, \dots, Y_n$  variáveis independentes com média  $\mu_i$  e variância  $\sigma_i^2$ . Se  $T = Y_1 + Y_2 + \dots + Y_n$ , então a distribuição de

$$\frac{T - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}}$$

se aproxima da distribuição normal padrão  $N(\mu = 0, \sigma^2 = 1)$  à medida que  $n$  tende a infinito.

Uma descrição alternativa para o Teorema Central do Limite dada uma amostra independente e identicamente distribuída  $Y_1, Y_2, \dots, Y_n$ , onde  $E(Y_i) = \mu$  e  $Var(Y_i) = \sigma^2$  é:

$$\bar{Y} \underset{n \rightarrow \infty}{\sim} N \left( \mu, \frac{\sigma^2}{n} \right) \quad (1.14)$$

Embora existam vários elementos técnicos com relação à equação 1.8, é importante ressaltar a importância de sua interpretação. A equação não requer a definição de uma distribuição de probabilidade para  $Y_i$ , mas apenas as propriedades de independência e *identicamente distribuídas*. Ou seja, para uma variável aleatória com distribuição desconhecida, a média amostral para uma amostra independente e identicamente distribuída, suficientemente grande, converge para uma distribuição normal com média  $E(Y_i)$  e variância  $\frac{Var(Y_i)}{n}$ . Esta é uma importante propriedade aplicada aos modelos de regressão quando a variável resposta não possui uma distribuição normal.

#### Exemplo 1-1

Um investigador deseja estudar a possível relação entre o salário (em mil reais) e o tempo de experiência (em anos) no cargo de gerente de agências bancárias de uma grande empresa. Os dados são mostrados na figura 1.3.




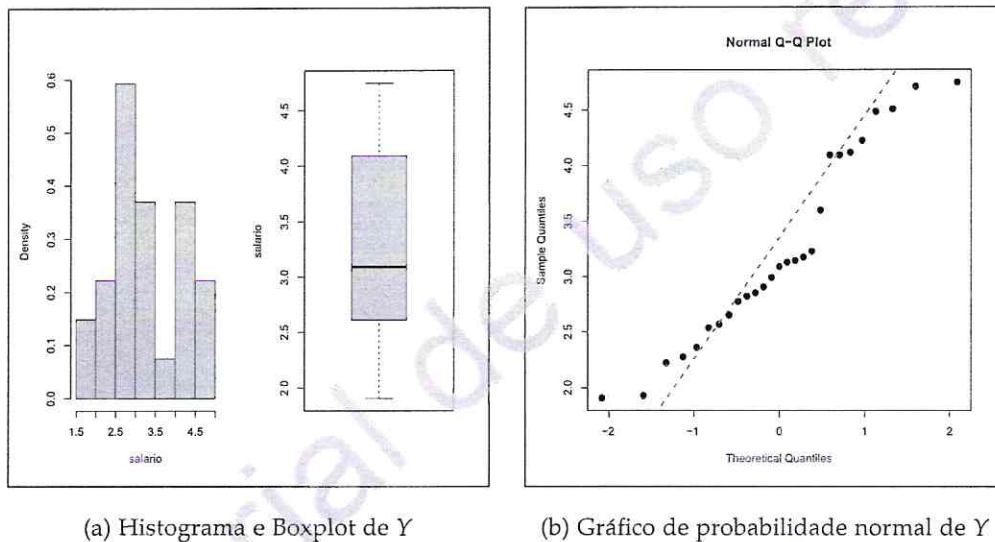


Figura 1.3: Exemplo: salário em função do tempo de experiência

Vamos considerar, inicialmente, que a informação sobre o tempo de experiência é inexistente. A variável aleatória de interesse é o salário ( $Y$ ). A figura 1.4 mostra o histograma e o boxplot (fig. 1.4 (a)) e o gráfico de normalidade (qqplot) (fig. 1.4 (b)) de  $y$ .



(a) Histograma e Boxplot de  $Y$

(b) Gráfico de probabilidade normal de  $Y$

Figura 1.4: Análise de resíduos para verificar a não correlação entre resíduo e média estimada, homocedasticidade, e seu comportamento segundo uma distribuição normal.

Neste caso, é possível assumir que a variável aleatória  $Y$  segue uma distribuição de probabilidade com média  $\mu$  e variância  $\sigma^2$ . A suposição de normalidade da variável aleatória  $Y$  pode ser investigada a partir de um gráfico de probabilidade normal, mostrado na figura 1.4 (b). Além da análise visual da característica de normalidade dos valores, é possível aplicar um teste de normalidade, mostrado a seguir.

```
> shapiro.test(salario)
Shapiro-Wilk normality test
data:  salario
W = 0.9344, p-value = 0.0884
```

O resultado do teste de normalidade indica a não-rejeição da hipótese nula (valor- $p = 0.0884$ ) de que os dados apresentam uma distribuição normal. Portanto, há evidência de que o com-

portamento da variável aleatória  $Y$  pode ser definido a partir de uma distribuição normal,  $Y \sim \text{Normal}(\mu, \sigma^2)$ . Os estimadores não viciados são:  $\hat{\mu} = 3.228$  e  $S^2 = 0.7367$ .

O modelo equivalente de regressão para este caso é definido como  $Y = \beta_0 + \epsilon$ , onde  $\beta_0$  é um parâmetro (determinístico) desconhecido e  $\epsilon \sim \text{Normal}(0, \sigma^2)$ . Este modelo apresenta as seguintes propriedades:  $E(Y) = \beta_0$  e  $\text{Var}(Y) = \sigma^2$ . Ou seja, neste modelo o parâmetro  $\beta_0$  representa a média da variável aleatória  $Y$  e a variável aleatória  $\epsilon$  caracteriza somente a componente de dispersão ( $\sigma^2$ ). Este é o modelo básico de uma análise de regressão. *Na ausência de potenciais variáveis preditoras, o modelo de regressão para o comportamento de uma variável aleatória  $Y$  com distribuição normal pode ser definido pela soma de uma constante e uma variável aleatória normal de média zero e variância  $\sigma^2$ .*

## 1.9 EXERCÍCIOS

### Exercício 1.1

Considere uma amostra independente e identicamente distribuída de  $n$  variáveis normais com média  $\mu$  e variância  $\sigma^2$ . Obtenha a expressão do estimador de máxima verossimilhança para o parâmetro de variância,  $\hat{\sigma}^2$ .

### Exercício 1.2

Considere uma amostra independente e identicamente distribuída de  $n$  variáveis aleatórias de bernoulli com parâmetro  $p$ ,  $Y_i \sim \text{Bernoulli}(p)$ . Obtenha a expressão do estimador de máxima verossimilhança para o parâmetro  $p$ .

### Exercício 1.3

Considere uma amostra independente e identicamente distribuída de  $n$  variáveis aleatórias de Poisson com parâmetro  $\mu$ ,  $Y_i \sim \text{Poisson}(\mu)$ . Obtenha a expressão do estimador de máxima verossimilhança para o parâmetro  $\mu$ .